

RAG 성능 변화 비교 보고서

최종 업데이트: 2026-05-15

목적: 특정 카테고리 문서 기반 RAG 검색 및 문서 초안 생성

검증 도메인: 이용약관 (예시 — 다른 도메인으로 교체 가능)

중요: 이 문서에서 "추정 효과"는 학술 연구 기반 추정치입니다.

실제 수치 측정은 `python3 eval/pipeline.py --all` 로 실행 가능합니다. (v0.3 평가 파이프라인 구축 완료)

비교 1: v0.1 초기 → v0.2

비교 기준: v0.1 초기 (Phase 1~4) vs v0.2 완료 (Phase 9)

시스템 구성 변화

구성 요소	v0.1 초기	v0.2 완료
검색 방식	벡터 검색 단독	BM25 + 벡터 + RRF 병합
임베딩 모델	multilingual-mpnet (768dim)	동일
chunk_size	500자	1,000자
chunk_overlap	50자	200자
청크 구분자	영문 기본값	한국어 문장 경계 10종 추가
인제스천 형식	PDF, DOCX, HWP	+ TXT, MD
컨텍스트 한도	4,000자	8,000자
프롬프트	도메인 고정	범용 문서 Q&A

청킹 실측 변화

동일 문서(3,160자)를 두 방식으로 청킹한 결과:

지표	v0.1 초기	v0.2 완료	변화
청크 수	7개	4개	-43%
청크 평균 길이	454자	907자	+100%
overlap	50자 (10%)	200자 (20%)	+4배
구분자	영문 기본	한국어 종결어미 우선	질적 변화

검색 방식 구조 변화

v0.1 초기: 벡터 검색 단독

쿼리 → 임베딩 → ChromaDB 유사도 검색 → top_k 청크 → LLM

- 정확한 키워드가 포함된 청크를 놓칠 수 있음
- 예: "해지 시 환불" 검색 시 "환불"이 직접 언급된 청크 누락 가능

v0.2 완료: 하이브리드 검색

쿼리
├ 임베딩 → 벡터 검색 (의미 유사도)
└ 토큰나이징 → BM25 검색 (키워드 매칭)

↓
RRF 점수 병합 → top_k 청크 → LLM

측정 가능한 변화: 청크 평균 길이 +100% (실측)
추정 변화: 검색 Recall +5~15% (BEIR 벤치마크 기준)

비교 2: v0.2 → v0.3

비교 기준: v0.2 완료 (Phase 9) vs v0.3 완료 (Phase 12)

시스템 구성 변화

구성 요소	v0.2 완료	v0.3 완료
임베딩 모델	multilingual-mpnet (768dim, 50개 언어)	multilingual-e5-large (1024dim, 94개 언어)
e5 prefix 처리	없음	passage: / query: 자동 적용
재순위	없음	Cross-Encoder (mmarco-mMiniLMv2-L12-H384-v1)
검색 후보 수	top_k개 직접 사용	top_k×4 후보 → Cross-Encoder → top_k
평가 파이프라인	없음	Precision@K / Accuracy / Faithfulness 자동 측정
출처 메타데이터	temp 경로 저장 (버그)	원본 파일명 저장 (수정 완료)
도메인	범용	이용약관 특화 (4개 문서 인제스천)

임베딩 모델 변화

항목	v0.2 (mpnet)	v0.3 (e5-large)
차원	768	1024
지원 언어 수	50개	94개
MTEB 다국어 순위	중위권	상위권
prefix 필요	없음	passage: / query:
추정 정확도 향상	—	+3~8%p

재순위 파이프라인 추가

v0.2: 단일 패스

쿼리 → BM25+Vector → top_5 → LLM
(후보 5개)

v0.3: 2-stage 검색

쿼리 → BM25+Vector → top_20 → Cross-Encoder 재순위 → top_5 → LLM
(후보 20개) (정밀 재순위)

- 초기 검색의 낮은 순위에 묻혀 있던 관련 청크를 Cross-Encoder가 재발굴
- 추정 효과: NDCG@10 기준 +5~12%p (학술 벤치마크)

현재 인제스천 상태

파일명	청크 수	비고
다음 이용약관.txt	~32개	일반 이용약관
다음 위치기반서비스 이용약관.txt	~16개	위치기반서비스 약관
네이버 위치기반서비스 이용약관.txt	~10개	위치기반서비스 약관
네이버 이용약관.txt	~31개	일반 이용약관
합계	~89개	

비교 3: v0.3 → v0.4 (Phase 13)

비교 기준: v0.3 완료 (Phase 12) vs v0.4 Phase 13 완료

시스템 구성 변화

구성 요소	v0.3 완료	v0.4 Phase 13
doc_type 메타데이터	없음	일반약관 / 위치기반약관 저장
인제스션 API	POST /ingest (파일만)	POST /ingest + doc_type Form 파라미터
쿼리 API	POST /query (질문만)	POST /query + doc_type JSON 필드
검색 필터	전체 문서 대상	doc_type 지정 시 해당 유형만 검색
Streamlit UI	파일 업로드만	문서 유형 selectbox 추가 (인제스션/쿼리 탭)
입력 검증	없음	_VALID_DOC_TYPES 허용 목록 — API/모델 양쪽

Precision@5 변화 (실측)

케이스	v0.3	v0.4 Phase 13	변화
tc-05 위약금/손해배상	0.2	0.4	+0.2 ✓
tc-09 이용자의무	0.2	0.2	변화 없음 *
나머지 8개	0.4~0.8	0.4~0.8	회귀 없음
전체 평균	0.46	0.48	+0.02

* tc-09는 위치기반약관 침범이 아닌 다음 이용약관 청크 풀림 현상 — MMR 필요

전체 버전 누적 비교

	v0.1 초기	v0.2 완료	v0.3 완료	v0.4 Phase 13	2026-05-15
검색 방식	벡터 단독	하이브리드	하이브리드+재순위	하이브리드+재순위+필터	실제 RAG 경로 다양성 선택
임베딩 차원	768dim	768dim	1024dim	1024dim	
지원 언어	50개	50개	94개	94개	
재순위	없음	없음	Cross-Encoder	Cross-Encoder	Cross-Encoder
doc_type 필터	없음	없음	없음	✓ 일반약관/위치기반약관	✓ 4개 카테고리 기준
호환					
청크 평균 길이	454자	907자	907자	907자	
컨텍스트 한도	4,000자	8,000자	8,000자	8,000자	
파일 형식 지원	3종	5종	5종	5종	
평가 파이프라인	없음	없음	✓ 구축 완료	✓ 실측 완료	✓ RAG/vector 지표 분리
+정규화					
Precision@5 평균	미측정	미측정	0.46	0.48	vector 0.48 /
RAG 0.60					

생성 품질	미측정	미측정	기준선 구축	accuracy 0.70	accuracy 1.0 /
faithfulness	1.0				

비교 4: v0.4 Phase 13 → 2026-05-14 검색 품질 1차 개선

비교 기준: eval/results/eval_20260513_164755.json vs eval/results/eval_20260514_113849.json

시스템 구성 변화

구성 요소	Before	After
RAG 검색 API	query() 내부에 검색과 생성 결합	retrieve() 로 검색 단계 분리
eval retrieval	vector-only와 LLM query 의존 혼재	LLM 없이 실제 RAG 검색 경로 측정
최종 청크 선택	rerank top_k 직접 사용	상위 후보 창 안에서 source 다양성 보존
doc_type 전달	full eval query 경로에서 누락	RAGEngine.query(..., doc_type=...) 전달

실측 지표 변화

Metric	Before	After	Delta
vector_precision@k_mean	0.48	0.48	0.00
rag_precision@k_mean	0.54	0.60	+0.06
source_coverage@k_mean	0.925	1.0	+0.075
accuracy_mean	0.675	0.70	+0.025
faithfulness_mean	0.8	0.9	+0.1
not_found_rate	0.1	0.1	0.0

케이스별 주요 변화

Case	변화
tc-04	rag_precision_at_k 0.4 → 0.8, source_coverage_at_k 0.5 → 1.0
tc-07	rag_precision_at_k 0.6 → 0.8, source_coverage_at_k 0.75 → 1.0
tc-09	answer_accuracy 0.5 → 0.75
tc-10	faithfulness 0.0 → 1.0

상세 before/after는 docs/references/2026-05-14-before-after.md 에 기록한다.

비교 5: 검색 품질 1차 개선 → 평가셋 정합성 보정

비교 기준: eval/results/eval_20260514_113849.json vs eval/results/eval_20260514_152044.json

변경 내용

Case	Before	After
tc-01	해지 시 환불 정책 질문	문서 근거가 있는 해지 후 데이터/게시물 처리 질문
tc-03	exact keyword 중심	이용 제한/정지/금지 표현 OR group 보정
tc-04	자동 갱신과 해지 복합 질문	자동 갱신 근거 부족을 인정하고 해지/데이터 처리 근거 평가
tc-09	일부 표현 불일치	권리/보유 등 약관식 표현 일부 허용

실측 지표 변화

Metric	Before	After	Delta
precision@k_mean	0.48	0.48	0.00
vector_precision@k_mean	0.48	0.48	0.00
rag_precision@k_mean	0.60	0.60	0.00
source_coverage@k_mean	1.0	1.0	0.0
accuracy_mean	0.70	0.875	+0.175
faithfulness_mean	0.90	1.0	+0.10
not_found_rate	0.10	0.0	-0.10

검색 경로는 바꾸지 않았기 때문에 검색 지표는 유지됐다. 개선은 문서 근거와 평가 질문/키워드 정합성을 맞춘 결과다.

상세 결과는 docs/references/2026-05-14-eval-case-alignment.md 에 기록한다.

비교 6: 평가셋 정합성 보정 → Retrieval metric 정규화

비교 기준: eval/results/eval_20260514_152044.json vs eval/results/eval_20260514_164724.json

변경 내용

항목	Before	After
source precision	고유 source 수를 top_k=5 로 나눔	기존 지표 유지
source 수 상한 보정	없음	normalized_source_precision@k 추가
context purity	명시 지표 없음	chunk_precision@k 추가
source recall	source_coverage@k 이름으로 제공	source_recall@k alias 추가

새 기준선

Metric	Value
precision@k_mean	0.48
rag_precision@k_mean	0.60
rag_normalized_source_precision@k_mean	1.0
rag_chunk_precision@k_mean	0.96
source_recall@k_mean	1.0
accuracy_mean	0.90
faithfulness_mean	1.0
not_found_rate	0.0

기존 rag_precision@k_mean=0.60 은 낮은 검색 성능이 아니라 현 metric 설계의 상한이다. 새 지표 기준으로 RAG 검색 경로는 source recall과 normalized source precision에서 모두 1.0이다.

상세 결과는 docs/references/2026-05-14-retrieval-metric-normalization.md 에 기록한다.

비교 7: Retrieval metric 정규화 → Faithfulness context 선택 개선

비교 기준: eval/results/eval_20260514_180006.json vs eval/results/eval_20260515_110900.json

변경 내용

항목	Before	After
faithfulness judge context	검색 결과 상위 context 일부를 그대로 사용	질문/답변 overlap과 source diversity 기반으로 judge용 context 선택
주요 실패 케이스	tc-10 에서 무관 context 혼입으로 faithfulness=0.0	tc-10 단건 및 full eval에서 faithfulness 안정화

실측 지표 변화

Metric	Before	After	Delta
accuracy_mean	0.975	0.95	-0.025
faithfulness_mean	0.90	1.0	+0.10
not_found_rate	0.0	0.0	0.0

accuracy_mean 하락은 검색/생성 회귀보다 잔여 keyword 표현 차이에 따른 감점으로 분류됐다. 따라서 다음 단계는 답변 로직 변경이 아니라 keyword 기준 정합성 재검토로 진행했다.

상세 결과는 docs/references/2026-05-15-faithfulness-eval-stability.md 와 docs/exec-plans/completed/2026-05-15-faithfulness-context-selection.md 에 기록한다.

비교 8: Faithfulness context 선택 개선 → 잔여 keyword accuracy 보정

비교 기준: eval/results/eval_20260515_110900.json vs eval/results/eval_20260515_135903.json

변경 내용

Case	Before	After
tc-03	이용 제한 exact keyword 중심	"이용이 제한", "제한될" 등 자연 표현 허용
tc-07	책임/손해 exact keyword 중심	귀책사유, 고의·과실, 불가항력, 장애/방해 등 면책 표현 허용
tc-09	준수/약관/정책/권리/보유 중심	권한, 부여, 라이선스, 명예, 불이익, 복제/유통 표현 추가
tc-10	"귀속" exact keyword 중심	"보유", "보유하게" 표현 허용

실측 지표 변화

Metric	Before	After	Delta
precision@k_mean	0.48	0.48	0.00
vector_precision@k_mean	0.48	0.48	0.00
rag_precision@k_mean	0.60	0.60	0.00
rag_normalized_source_precision@k_mean	1.0	1.0	0.0
rag_chunk_precision@k_mean	0.96	0.96	0.0
source_recall@k_mean	1.0	1.0	0.0
source_coverage@k_mean	1.0	1.0	0.0
accuracy_mean	0.95	1.0	+0.05
faithfulness_mean	1.0	1.0	0.0
not_found_rate	0.0	0.0	0.0

현재 10개 평가 케이스 기준으로 생성 품질 핵심 지표는 상한에 도달했다. 다음 비교 측은 모델/검색 추가 튜닝이 아니라 평가셋 일반화, hard case 확장, keyword 기반 판정 한계 점검이다.

상세 결과는 docs/references/2026-05-15-residual-keyword-accuracy.md 에 기록한다.

실측 평가 실행 방법

v0.3에서 평가 파이프라인이 구축되어 실제 수치 측정이 가능합니다.

```
# retrieval 지표만 측정 (빠름, Ollama 불필요)
python3 eval/pipeline.py --metric retrieval

# 전체 지표 측정 + JSON 리포트 저장
python3 eval/pipeline.py --all

# 결과: eval/results/eval_{YYYYMMDD_HHMMSS}.json
```

평가 케이스: eval/test_cases.json — 이용약관 도메인 10개 질문

relevant_sources 매핑: 완료 (Precision@K 즉시 측정 가능)

변경되지 않은 항목

항목	이유
chunk_size	v0.2에서 최적화 완료 (1,000자)
RRF 알고리즘	v0.1부터 적용 중, 변경 필요 없음
ChromaDB cosine	의미 검색 기준으로 적합

다음 단계

- 1. 최신 full eval 리포트 eval/results/eval_20260515_135903.json 기준 현재 10개 케이스의 상한 도달 상태를 확인한다.
- 2. keyword OR group이 현재 케이스에 과적합됐는지 검토한다.
- 3. hard case 후보를 3건 이상 추가해 평가셋 확장 계획을 수립한다.

최종 업데이트: 2026-05-15 — accuracy/faithfulness/not_found 현재 평가셋 상한 달성